图像分类实验报告

Intel 六类场景 · CNN 基础模型与数据增强对照

当前权重复核结果：基础模型 86.10%，增强模型 85.63%。按验证准确率分别选择第 19、19 轮；本次整理不重新训练。

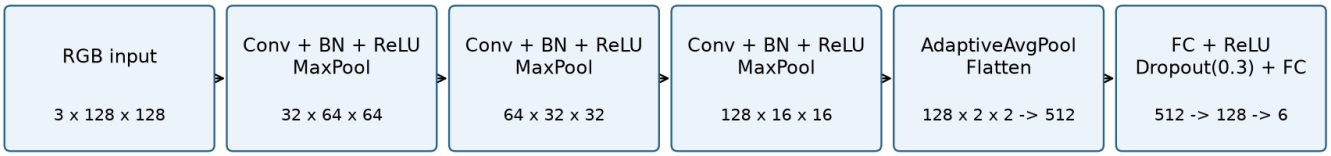
1 数据与实验协议

类别为 buildings, forest, glacier, mountain, sea, street。原训练目录 14,034 张，以种子 42 按 80% / 20% 划分：训练 11,227 张、验证 2,807 张；测试目录 3,000 张。两组实验使用同一划分。

图片转为 RGB 并缩放至 128×128；ToTensor 后以均值 0.5、标准差 0.5 归一化。验证、测试采用确定性变换。此处独立测试指测试目录不参与训练梯度更新；未进行跨目录重复图片审计。

2 模型结构

SceneCNN | 159,910 trainable parameters | Conv kernels: 3 x 3

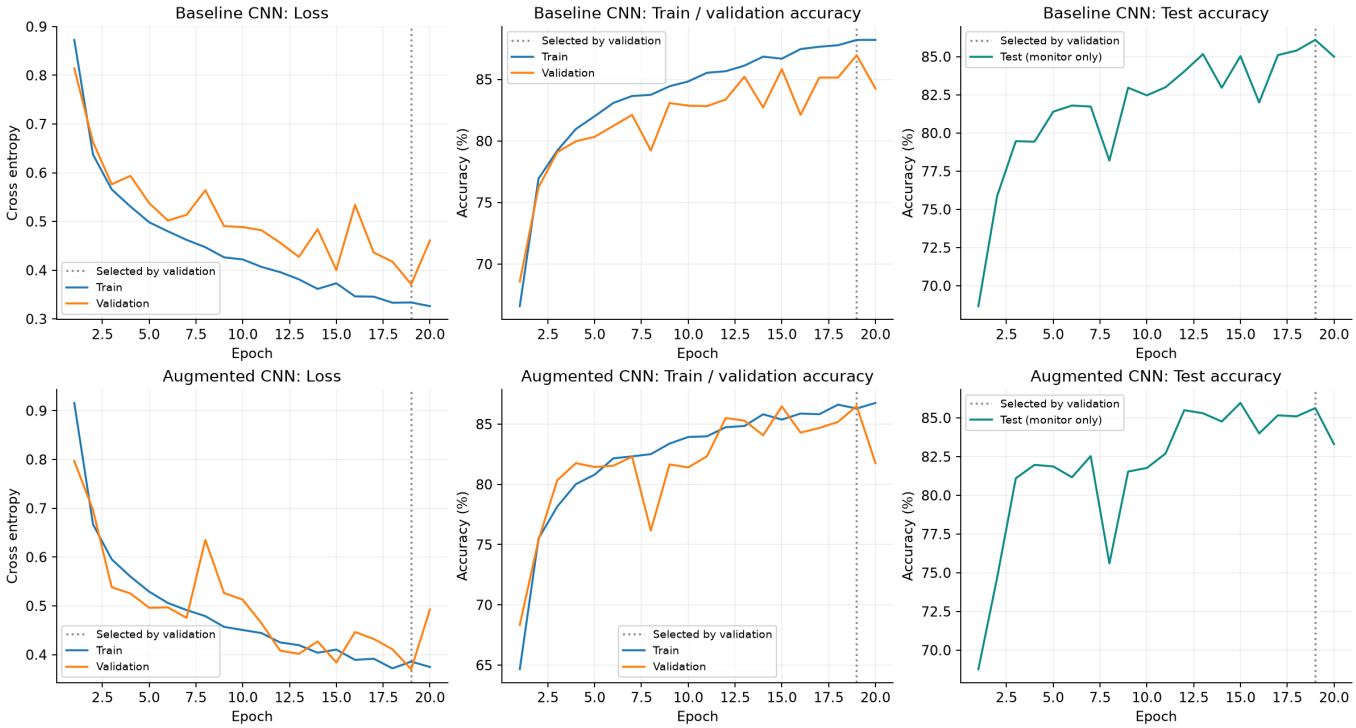


三个卷积块依次包含 3×3 卷积、BatchNorm、ReLU 和 2×2 最大池化，通道为 32、64、128。卷积共享权重提取局部纹理，非线性与池化逐步形成场景特征。自适应平均池化至 2×2 后展平，接 512→128→6 分类头，中间使用 Dropout(0.3)。共 159,910 个参数。

交叉熵直接接收 logits，推理取 argmax。图片标题显示 softmax 最大分数，未作置信度校准，不能当成已验证的正确概率。

3 训练设置与过程

配置	两种实验共同设置
优化	AdamW；lr=0.001；weight_decay=0.0001；交叉熵
训练	20 轮；batch_size=64；仅按验证准确率保存最佳模型
设备	NVIDIA GeForce RTX 5070 Laptop GPU



增强版仅改变训练变换：随机裁剪缩放（scale 0.8~1.0、ratio 0.9~1.1）、概率 0.5 的水平翻转、亮度/对比度/饱和度幅度均为 0.15 的颜色扰动。它们增加场景变化，也可能裁掉重要信息。

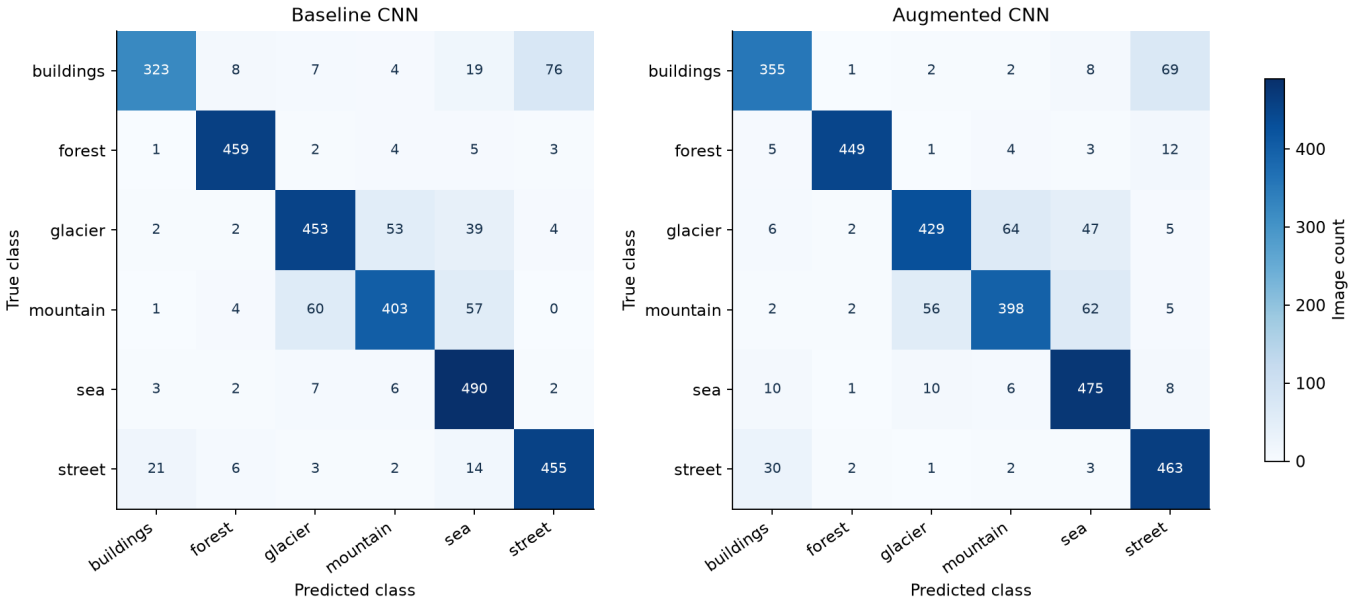
竖线为验证集选中的轮次。训练指标在训练模式及批次更新中统计，增强版使用增强输入，因此与固定权重的验证指标存在口径差别。损失按样本数加权平均。最后一轮不一定为最佳轮次。

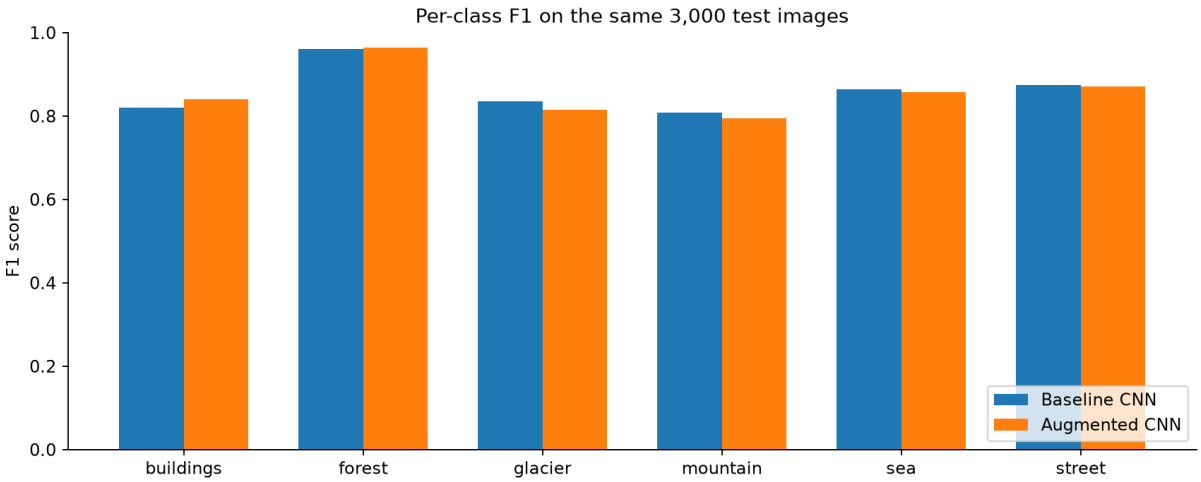
测试准确率每轮仅用于监测，不参与梯度更新或权重选择；训练期间已经查看测试曲线，不能描述为完全盲测。Windows 使用单进程四线程、有界四批预读，避免多进程共享内存错误；线程随机增强不保证逐位复现。

4 当前最佳模型的最终测试

模型	轮次	验证 Acc	测试 Acc	Macro F1
基础 CNN	19	86.96%	86.10%	0.8605
增强 CNN	19	86.50%	85.63%	0.8574

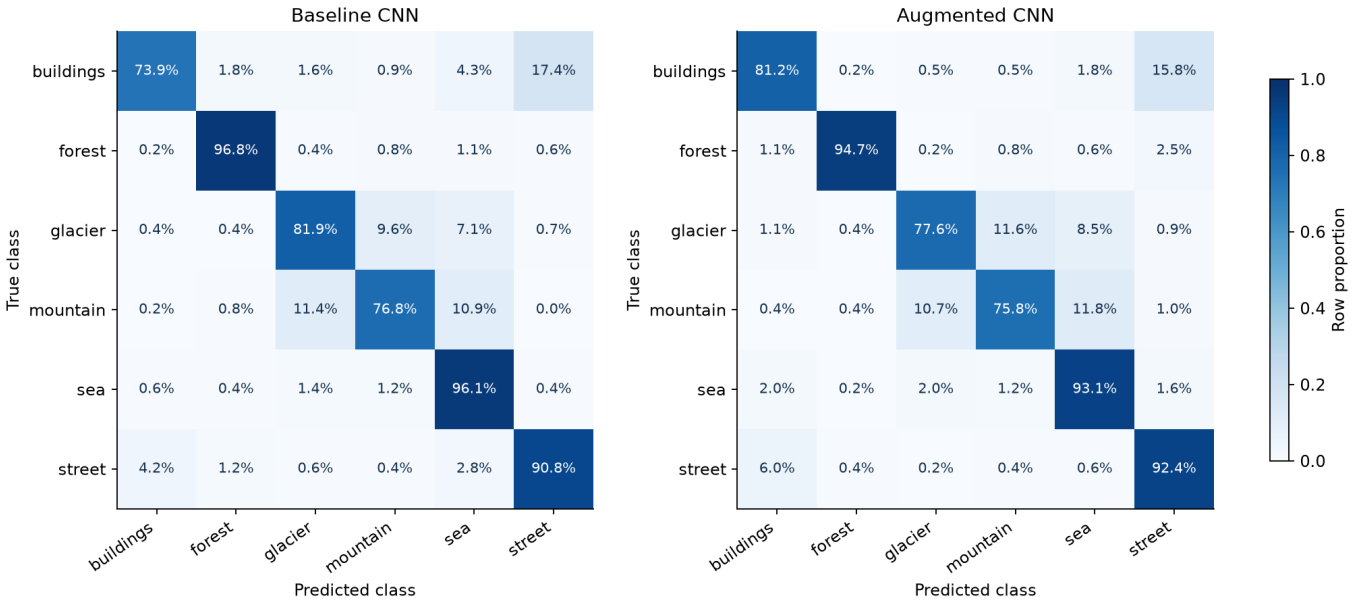
基础模型正确 2583/3000 张，增强模型正确 2569/3000 张；增强减基础为 -0.47 个百分点。本次增强未带来测试准确率提升，不能写成改进成功。按照验证成绩，当前建议使用基础 CNN。单次训练不能支持统计优势结论。





混淆矩阵行是真实类别，列是预测类别。Accuracy 为正确比例；Precision=TP/(TP+FP)，Recall=TP/(TP+FN)，F1=2PR/(P+R)。Macro F1 对类别等权，weighted F1 按真实样本数加权；零分母时定义为零。逐类指标已保存为 CSV。

5 错误分布与改进分析



上图按真实类别逐行归一化，各行合计 100%，对角线即该类召回率。它可以在类样本数不同的情况下比较漏分情况。

基础模型主要混淆：buildings→street 76 张；mountain→glacier 60 张；mountain→sea 57 张。

增强模型主要混淆：buildings→street 69 张；glacier→mountain 64 张；mountain→sea 62 张。

这些统计说明错误出现的位置，不能单独证明成因。相近场景可能具有相似颜色、纹理或混合主体，应结合原图判断。当前增强可能改变关键场景线索，也可能受训练波动影响，不能只凭一次对照下因果结论。

后续可使用验证集比较更温和的裁剪、学习率调度、早停或轻量注意力模块；固定方案后再做最终评价。应增加多随机种子实验，并同时记录准确率、F1 和实际推理耗时，避免仅报告有利指标。

6 ViT 原理理解

ViT 将图像分成固定大小的 patch，展平并线性映射为 token，加入位置编码后送入 Transformer Encoder。多头自注意力通过 Q、K、V 建模不同位置之间的关联，计算形式为 softmax(QK^T/sqrt(d))V；原始 ViT 使用可学习分类 token 汇聚信息，再由分类头预测。

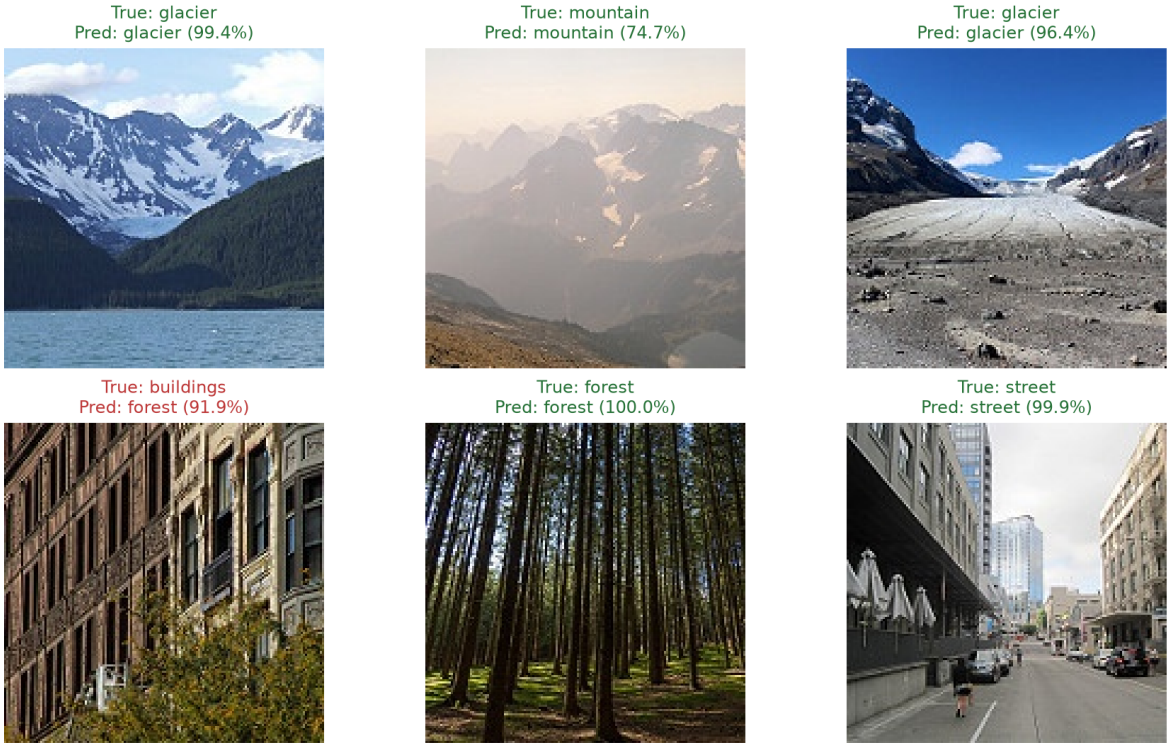
卷积具有局部感受野与权重共享，自注意力可直接关联远距离 patch；常规全局注意力的计算和内存成本随 token 数近似二次增长。效果依赖数据规模与训练方案。本项目仅说明原理，实际完成 CNN 和增强对照，没有训练 ViT 或编造其成绩。

参考：Dosovitskiy 等，An Image is Worth 16x16 Words，arXiv:2010.11929。

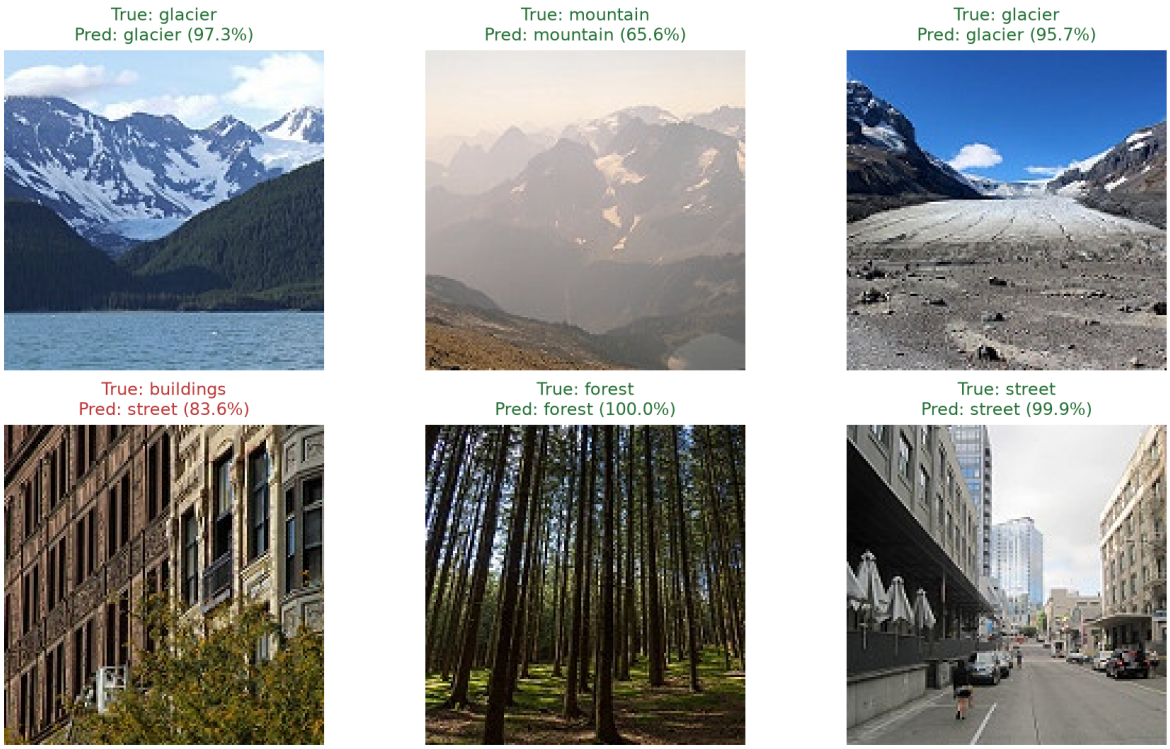
7 同一批随机测试图片的分类结果

固定种子 2026，从全部测试图片随机抽取六张，两种模型展示相同图片。绿色为预测正确，红色为预测错误；括号内为 softmax 分数。

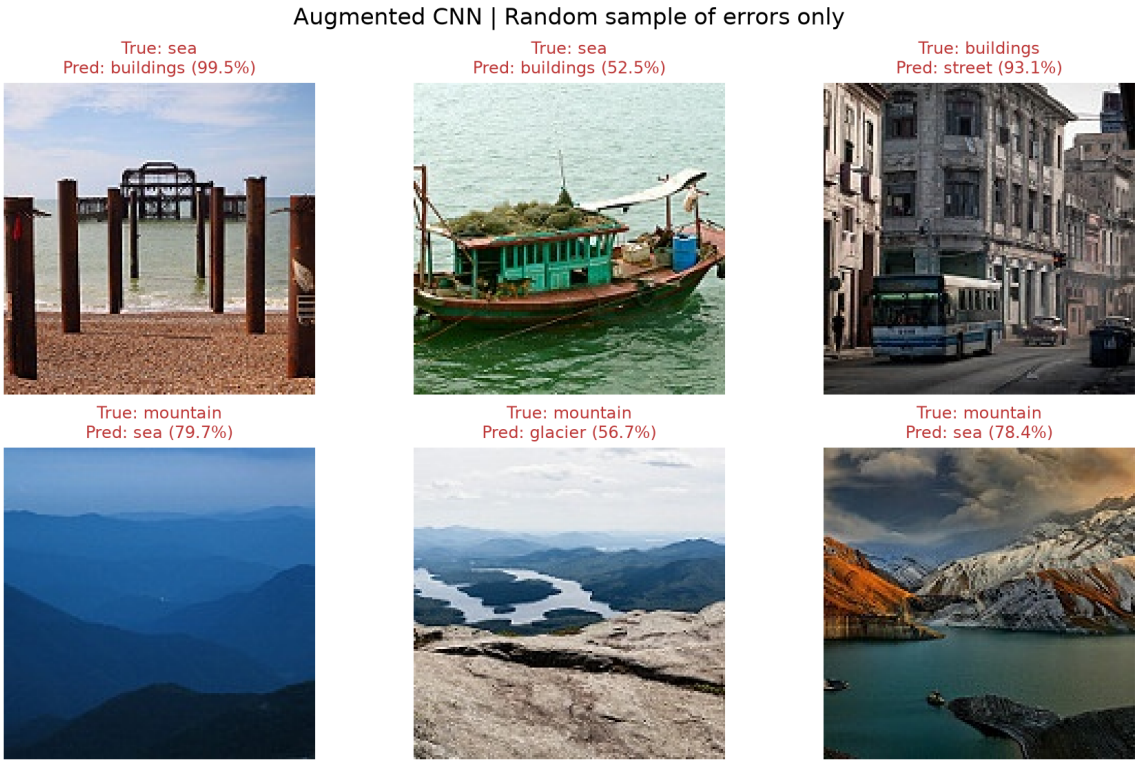
Baseline CNN | Same randomly selected test images



Augmented CNN | Same randomly selected test images



8 错误案例与复核方法



上图从增强模型全部错误中固定随机抽取六张，仅用于错误分析，不代表整体准确率。随机索引见 sample_indices.json；每张测试图的真实类别、预测类别及六类 softmax 分数见 predictions.csv。

现有权重直接运行 05_finish_classification.py，即可重新测试并生成八张图、全部 CSV、summary.json 和 Markdown 报告。06_predict_image.py 接收一张本地图片，可选择基础或增强权重；完整命令见项目 README。

05 会核对最佳轮次、验证准确率及对应轮次的测试成绩，记录权重与历史 SHA-256，避免混用旧记录。若模型或数据更改，需重训或重新复核，不应手工修改指标。05 不自动更新 PDF；请再运行 07_export_report_pdf.py 导出。

环境：Python 3.11.17；PyTorch 2.10.0+cu128；torchvision 0.25.0+cu128。提交包包含源码、两组最佳权重、20 轮历史、图表、指标和报告；不包含大体积原始图片，当前电脑可直接沿用 dataset。

数据集参考：Intel Image Classification（Kaggle）。

结果仅对应本次保存权重与现有数据；两次实验属于单次训练比较，没有多随机种子验证、置信度校准或跨目录重复图片审计。